

ContratIA Abierta

Sistema de ingeniería de datos para priorizar la revisión humana de la contratación pública en Colombia.

No detectamos corrupción. Ordenamos qué revisar primero, con evidencia trazable.

90.431 procesos reales

Validado vs control fiscal 2.5×

Caso real: Puerto Gaitán

Embeddings semánticos

Triage, no detección: la capacidad humana < el volumen

Colombia publica más de 2 millones de procesos de contratación al año en SECOP. Las oficinas de control interno y veedurías no pueden revisarlos todos. La pregunta operativa real es: ¿qué se revisa primero esta semana?



ContratIA Abierta convierte un océano de procesos en una cola priorizada y auditable.

Qué SÍ hace y qué NO hace el sistema

SÍ HACE

- Ranking 0–100 explicable de procesos a revisar.
- Comparables semánticos por categoría + embeddings.
- Alineación plan (PAA) vs ejecución (SECOP II).
- Razones legibles + confianza de datos visible.
- Trazabilidad: fuente, fecha, snapshot, hash.

NO HACE

- No declara corrupción, fraude ni responsabilidad.
- No reemplaza auditoría jurídica ni fiscal.
- No deanonimiza más allá del dato público.
- No usa contexto fiscal como etiqueta del modelo.
- No reemplaza la decisión humana: la informa.

Un score alto significa “revísalo primero con evidencia”, no “es corrupción”.

Para quién es y qué decide cada semana

Usuario primario

Decide qué procesos auditar esta semana con capacidad limitada.

Control interno / transparencia

Secundario

Prioriza casos con evidencia para denuncia documentada.

Veeduría ciudadana

Secundario

Encuentra patrones territoriales con trazabilidad.


Periodista de datos

DECISIÓN SEMANAL

“De los procesos publicados, ¿cuáles 20 revisamos primero y por qué?”

El sistema convierte esa pregunta en una cola priorizada y auditable.

Cuatro datasets oficiales del ecosistema Datos Abiertos Colombia



Una sola lane de ingeniería de datos, de extremo a extremo




Reproducible end-to-end

PostgreSQL es la fuente de verdad relacional; MongoDB guarda evidencia documental y eventos. Stack: Python 3.11 · uv · Polars · FastAPI · Dash · Docker Compose.

PostgreSQL como fuente de verdad: 33 objetos públicos

Modelo relacional agrupado



El detalle completo vive en `sql/001_schema.sql` y `db/migrations/001_schema.sql`.

GARANTÍAS

PK / FK	integridad referencial
CHECK	score 0-100, conf 0-1
Índices	consulta analítica
Vistas	ranking + PAA
Triggers	auditoría + historial

27 tablas + vistas + triggers = 33 objetos. Diseño normalizado con auditoría incorporada.

Lo que un evaluador técnico espera ver

Triggers

audit_log · historial de estados · updated_at

Window functions

concentración por entidad · outliers · percent_rank

CTE recursiva

jerarquía territorial departamento → municipio

Transacciones

score + evento de auditoría atómico

```
-- Window: percentil global del score (usado en el ranking)
SELECT process_id, priority_score,
       round(100*percent_rank() OVER (ORDER BY priority_score),2)
       AS score_percentile
FROM v_ranking_processes;  -- 'top 0.5%' en vez de '85/100'
```


Cuatro componentes auditables → un número 0-100

Anomalía • 45%

IsolationForest sobre features numéricas

Pares • 35%

Desviación vs procesos comparables
UNSPSC

Reglas • 20%

Thresholds verificables (valor, plazo, PAA)

Confianza

0-1 según cobertura de datos (aparte)

```
score = round(100 · σ(0.45·anomalía + 0.35·pares + 0.20·reglas))
```

INTERPRETACIÓN: percentil, no nota absoluta

El score se normaliza por cuantiles del dataset. Un score de 91 = “top 0.02% más atípico de 90.431”, no “91% corrupto”. Distribución de triage: mediana 7, p95 ≈ 45, solo 0.5% supera 70.

Embeddings multilingües funcionando (no humo)

El matching plan ↔ ejecución y los comparables usan un proveedor semántico configurable. Por defecto: embeddings neuronales MiniLM multilingüe; fallback robusto a TF-IDF si no hay modelo. Ambos comparten la misma abstracción.

SentenceTransformer (default)

paraphrase-multilingual-MiniLM-L12-v2
Carga en ~11s · offline · sin API key

TF-IDF (fallback)

scikit-learn · cero dependencias pesadas
Garantiza que la demo nunca se cae

PRUEBA DE DISCRIMINACIÓN SEMÁNTICA (medida en vivo)


$\text{sim}(\text{"acueducto"}, \text{"alcantarillado"}) = 0.611$

$\text{sim}(\text{"acueducto"}, \text{"papelería"}) = 0.136$

El modelo entiende significado: agrupa contratos de agua y separa los no relacionados.

¿El score se concentra donde el control fiscal ya miró?

Prueba ciega: cruzamos las entidades que la Auditoría General (AGR, wasc-xi4h) puso bajo vigilancia fiscal contra nuestro score. El modelo nunca vio esa etiqueta.



2.46x
enriquecimiento en tasa de alta prioridad

19
mediana — vigilada

7
mediana — resto

Auditoría AGR / conducta indebida probada: mide selección para revisión fiscal. Que el score enriquezca ese grupo valida el triage, no acusa.

Puerto Gaitán: el sistema prioriza donde la Contraloría ya halló señal

REGISTRO PÚBLICO

La Contraloría documentó irregularidades vigentes en Puerto Gaitán: contratos de agua/acueducto (hallazgo > \$14.700 millones), sistemas fotovoltaicos (\$8.901 millones, 2025) y manejo de regalías.

NUESTRO SISTEMA, A CIEGAS

Marca Puerto Gaitán 3.1× sobre la tasa nacional. Su proceso top priorizado es una construcción de acueducto de \$42.408 millones (score 87) — misma entidad y categoría que señaló la Contraloría. No usamos esa información para entrenar.



EL CONTRAEJEMPLO QUE DA CREDIBILIDAD

Puerto Gaitán	3.1×
Departamento del Meta	2.9×
Gobernación de Casanare	1.0× (promedio)
Alcaldía de Villavicencio	0.7× (debajo)

Casanare (escándalos de hace 10+ años) puntúa en el promedio: el sistema detecta estructura del proceso actual, no reputación histórica. No es una lista negra.

Tres zonas por el trabajo del usuario, no por features

CONCURSO DATOS AL ECOSISTERA 2026 · GOBERNANZA Y TRANSPARENCIA

ContratIA Abierta

Sistema de priorizacion de revision contractual. Ordena procesos SECOP por nivel de riesgo estadistico para decidir que revisar primero. No acusa ni prueba corrupcion.

Esta herramienta prioriza revision humana. No prueba corrupcion, fraude, responsabilidad fiscal ni responsabilidad juridica; requiere contraste con la fuente primaria.

Proyecto

1 · DECIDIR

2 · ENTENDER

3 · CONFIAR

LENTE TERRITORIAL

Toda la Orinoquia (Meta + Casanare)

QUE REVISAR PRIMERO

CO1.REQ.10301976

Primer candidato por score y confianza.

POR QUE ESTA PRIORIZADO

Score alto + soporte visible

La prioridad ordena revision; la confianza indica cobertura.

ACCION HUMANA SIGUIENTE

Abrir SECOP y contrastar

Abrir SECOP, contrastar fuente, registrar criterio.

91.0

Score del primer candidato

85.0

Confianza del primer candidato

90,431

Procesos

344

Entidades

2,843

Proveedores

0.5%

Alerta prioritaria

100.0%

Match PAA fuerte

Esta herramienta prioriza revision humana. No prueba corrupcion, fraude, responsabilidad fiscal ni responsabilidad juridica; requiere contraste con la fuente primaria.

COLA SEMANAL DE REVISION

Top 10 procesos a revisar esta semana

Procesos con mayor score de prioridad. Cada uno incluye razon principal y accion sugerida.

#	REFERENCIA	ENTIDAD	DEPTO	MODALIDAD	VALOR BASE
1	015-00-E-CACOM-2-GRUTE-2026 (Presentación de oferta)	CACOM-2	Meta	Selección abreviada subasta inversa	\$588,069,846
2	LP-DAP1-03-2026 (Fase de Selección (Presentación de ofertas))	ALCALDIA DE GUAMAL - META	Meta	Licitación pública Obra Publica	\$16,927,383,309
3	RSC-CP-007-2025	RED SALUD CASANARE E.S.E. *	Casanare	Contratación régimen especial (con ofertas)	\$15,810,083,570
4	007-00-E-CACOM-2-GRUTE-2025 (Presentación de oferta)	CACOM-2	Meta	Selección abreviada subasta inversa	\$805,668,200

1 • DECIDIR

Qué revisar primero. Cola priorizada + filtro territorial + KPIs reales.


2 • ENTENDER

El caso: score desglosado, razones, comparables, PAA, contexto fiscal.

3 • CONFIAR

Por qué confiar: validación AGR, distribución, metodología, límites.

Métricas duras de un sistema reproducible



VALIDACIÓN CUBIERTA

- ✓ Schema integrity (PK/FK/CHECK)
- ✓ Join audit + fill rates
- ✓ Compuerta PAA top-1 ≥ 0.75
- ✓ Scoring bounds 0–100 / 0–1
- ✓ Enriquecimiento AGR 2.5×
- ✓ Caso real Puerto Gaitán 3.1×

Lo que falta — declarado, no oculto

LISTO

- ✓ 71 tests · lint estable · validación reproducible
- ✓ 90.431 procesos reales (Meta + Casanare)
- ✓ Embeddings semánticos funcionando + fallback TF-IDF
- ✓ Validación AGR 2.5× + caso real Puerto Gaitán

PENDIENTE (ROADMAP)

- Validación humana de 100 casos con dos revisores
- Benchmark formal embeddings vs TF-IDF (precision@k)
- Despliegue público read-only (Blueprint listo)
- Sesiones de usabilidad con 5 usuarios reales

La rúbrica premia una validación pendiente declarada por encima de una validación inventada.

ContratIA Abierta

Sin entrenar contra ninguna etiqueta de corrupción, el sistema prioriza 3.1× los contratos de Puerto Gaitán — donde la Contraloría halló irregularidades vigentes.

Detecta estructura, no reputación. Prioriza revisión humana con evidencia trazable.

EQUIPO

Ingeniería de Datos · Universidad del Rosario

REPOSITORIO

github.com/Thom-320/secop-risk-alerts-co

CATEGORÍA · REGIÓN

Gobernanza y Transparencia · Meta y Casanare